



Departamentul Automatică și Informatică Industrială

**Facultatea Automatică și Calculatoare
Universitatea Națională de Știință și Tehnologie
POLITEHNICA din București**

Splaiul Independenței 313, 060042, București, România
Sala ED 412, Tel. 021/402.92.69
www.aii.pub.ro, email: secretariat.aii@upb.ro



Sesiunea de Comunicări Științifice Studentești

Ediția 2026

Titlu lucrare :

**Sistem de Detecție a Deepfake-urilor Video bazat pe
Analiză Facială**

Autor: Vlăduțu Alexandru-Nicușor , an III , grupa 333AA

Adresa e-mail: alexandru.vladutu@stud.acs.upb.ro

Îndrumător științific : dr. conf. Stefan Mocanu

Cuprins:

1. Introducere	3
1.1 Democratizarea inteligenței artificiale generative.....	3
1.2 Deepfake ca o armă	3
1.2.1 Debutul și mecanismul tehnologiei	3
1.2.2 „Infocalipsa” și pierderea încrederii	4
1.2.3 Noile provocări pentru lege și justiție	4
2. Prezentarea domeniului din care face parte lucrarea.....	4
2.1 Concepte fundamentale de prelucrare Multimedia	4
2.1.1 Structura fluxului video.....	4
2.1.2 Reprezentarea imaginilor în calculator (RGB).....	4
2.1.3 Compresia video și artefactele	4
2.2 Diverse abordări asupra problemei	5
2.2.1 Abordarea Academică (FaceForensics++)	5
2.2.2 Abordarea Biometrică (Intel FakeCatcher)	5
2.2.3 Detectoarele Comerciale (API-uri Cloud).....	5
3. Descrierea problemei si prezentarea soluției propuse	5
3.1 Obiectivele proiectului	5
3.2 Abordarea aleasă în proiect	6
3.2.1 Fundamentarea teoretică a detecției și analiza artefactelor	6
3.2.2 Arhitectura convoluțională	7
3.2.3 Conceptul arhitectural Multi-Layer Fusion (MFNN).....	7
3.2.4 Alinierea dimensională și Funcția de decizie	8
4. Implementarea tehnică a aplicației.....	9
4.1 Arhitectura generală a sistemului	9
4.2 Preprocesarea datelor și detectarea facială	9
4.2.1 Tranziția de la metodele clasice la MediaPipe	9
4.2.2 Optimizarea algoritmului de extracție pentru Deepfake-uri.....	9
4.2.3. Standardizarea și redimensionarea setului de date	10
4.3. Arhitectura Multi-Layer Fusion Neural Network (MFNN)	10
4.3.1 Rețeaua de bază (backbone) și extragerea caracteristicilor	10
4.3.2 Alinierea dimensiunilor și fuziunea datelor	10
4.4 Metodologia de antrenare și optimizare (Fine-Tuning)	10
4.4.1. Augmentarea datelor pentru o generalizare optimă	11
4.4.2 Gestionarea dezechilibrului dintre clase	11
4.4.3 Optimizarea globală (Fine-Tuning).....	11
4.5 Evaluarea pe material video (Inferența)	11
4.5.1 Procesarea rapidă a cadrelor.....	11
4.5.2 Strategia de vot majoritar (Majority Voting)	12
4.6. Interfața grafică și testarea practică.....	12
4.6.1 Secțiunea de Input și Modurile de Analiză (Panoul din stânga)	13
4.6.2 Live Preview și recunoașterea facială (Centru).....	13
4.6.3 Verdictul final și Graficul de Încredere (Panoul din dreapta).....	13
4.6.4 Observații privind performanța și limitările modelului.....	14
5. Concluzii si planuri de viitor	15
5.1 Performanța obținută	15
5.2 Limitări.....	16

5.3 Dezvoltări viitoare.....	16
6. Bibliografie.....	16
7. Declarație privind utilizarea asistenței LLM.....	20

1. Introducere

1.1 Democratizarea inteligenței artificiale generative

În ultimii ani, inteligența artificială generativă a cunoscut o dezvoltare explozivă, generând o adevărată cursă a înarmării – atât între actorii statali, cât și între cei privați – pentru crearea celor mai bune modele. Modelele de limbaj de mari dimensiuni (LLM) au prins extrem de repede, devenind foarte populare în rândul publicului larg. Evoluția rapidă a tehnologiilor digitale, a prelucrării datelor și a automatizării a stârnit, atât așteptări uriașe, cât și temeri pe măsură. Dincolo de discuțiile legate de piața muncii, drepturi și libertăți, au apărut semne de întrebare serioase cu privire la impactul lor potențial asupra vieții politice și a democrației. [25]

Tehnologiile IA nu sunt neutre; ele reflectă în mod inerent valorile dezvoltatorilor lor și ale ecosistemului din care fac parte. Pe de o parte, ele au potențialul de a transparentiza și responsabiliza instituțiile publice, de a stimula participarea civică și de a face democrația mai incluzivă. Pe de altă parte, pot amplifica la fel de ușor tendințele autocratice, fiind instrumente redutabile de manipulare, folosite cu intenții malițioase. Integrarea rapidă a acestor tehnologii în platformele pe care le folosim zilnic oferă pârgii fără precedent pentru o influență ținută, personalizată și, de cele mai multe ori, insesizabilă. Astfel, tentația unor actori politici de a folosi IA în propriul avantaj este uriașă. [25]

Deși ne aflăm abia la început de drum, utilizarea inteligenței artificiale generative a devenit deja o obișnuință, acoperind nevoi dintre cele mai diverse – de la redactarea de texte legislative, până la căutarea unor rețete de gătit. Un studiu realizat de McKinsey & Company la mijlocul lunii aprilie 2023 subliniază tocmai acest aspect: în ciuda faptului că tehnologia abia devenise disponibilă publicului, experimentarea cu aceste instrumente era deja o practică răspândită. Concret, 79% dintre respondenți declaraseră că interacționaseră deja cel puțin o dată cu IA generativă, iar 22% afirmău că o folosesc în mod regulat la locul de muncă. [23]

1.2 Deepfake ca o armă

1.2.1 Debutul și mecanismul tehnologiei

În martie 2022, un videoclip trucat în care președintele Zelenski cerea capitularea Ucrainei a marcat prima utilizare majoră a unui deepfake într-un conflict armat. Aceste materiale – audio, video sau foto manipulate prin inteligență artificială – se bazează pe rețele generative antagoniste (GAN) [2]. Concret, un algoritm creează falsul, iar altul încearcă să-l detecteze, antrenându-se reciproc până când rezultatul devine extrem de greu de distins de realitate. Deși producerea unui fals de înaltă calitate necesită inițial timp și echipamente scumpe, codurile open-source și apariția serviciilor de tip deepfake-la-cerere au făcut ca această tehnologie să fie acum la îndemâna oricui, deschizând noi oportunități periculoase inclusiv pentru grupările extremiste. O trecere în revistă completă a metodelor de creare și detecție a deepfake-urilor este realizată în [19].

1.2.2 „Infocalipsa” și pierderea încrederii

Experții avertizează că ne îndreptăm cu pași repezi spre o „infocalipsă” – o eră în care oamenii vor refuza să mai crede informațiile care le contrazic propriile convingeri, acuzând că sunt fabricate. Unele estimări sugerează că, până în 2026, 90% din conținutul online ar putea fi generat sintetic. Problema majoră este că publicul larg nu este încă pregătit; studiile arată că până și cei care sunt convinși că pot detecta un deepfake sunt adesea păcăliți de materialele hiper-realiste, care pot fi generate acum chiar și în timp real, pe transmisiuni live.

1.2.3 Noile provocări pentru lege și justiție

Autorități precum Europol și Departamentul de Securitate Internă al SUA (DHS) consideră deepfake-urile drept una dintre cele mai mari provocări ale deceniului până în 2030.

Tehnologia este deja folosită cu succes în infracțiuni grave: clonarea vocilor pentru a simula răpiri, șantajul cu imagini intime truate (sextortion) sau chiar fabricarea de dovezi false în instanță. [34]

Pe lângă falsurile în sine, apare un fenomen la fel de periculos, numit **Liar's Dividend (Avantajul Mincinosului)**: posibilitatea ca persoanele publice sau infractorii să scape de acuzații susținând că dovezile reale împotriva lor sunt, de fapt, doar niște deepfake-uri. [21]

2. Prezentarea domeniului din care face parte lucrarea

2.1 Concepte fundamentale de prelucrare Multimedia

2.1.1 Structura fluxului video

Un videoclip digital este o reprezentare electronică a unor imagini vizuale în mișcare, stocate sub formă de date digitale codificate. Acesta constă într-o succesiune de imagini fixe (cadre) care, atunci când sunt redat rapid, creează iluzia mișcării, fiind însoțite, de regulă, de sunet.

Pentru că antrenarea rețelelor neuronale necesită un volum uriaș de date, am decis să nu procesez absolut toate cadrele din videoclipuri. Astfel, pentru a economisi timp și spațiu de stocare, am ales să extrag doar 3 cadre pe secundă – o rată care păstrează suficientă informație vizuală despre mișcărilor feței, fără a supraîncărca sistemul.

2.1.2 Reprezentarea imaginilor în calculator (RGB)

O imagine digitală este, în esență, discretizată sub forma unui tensor tridimensional – o structură matematică ce reține rezoluția (lățimea și înălțimea în pixeli) alături de canalele de culoare. În formatul clasic RGB, fiecare canal (Roșu, Verde, Albastru) este stocat pe 8 biți și primește o valoare de la 0 la 255. De exemplu, culoarea galbenă este codificată ca vectorul [255, 255, 0].

2.1.3 Compresia video și artefactele

Compresia video reduce drastic dimensiunea fișierelor fără a le afecta vizibil calitatea, permițând astfel streaming-ul rapid pe platforme precum YouTube sau Netflix. Algoritmii de compresie – standardizați în codec-uri globale precum H.264, H.265 și VP9 – elimină redundanța temporală (informații similare între cadre consecutive) și redundanța spațială (detalii pe care ochiul uman nu le percepe). [33]

Artefactele rezultate în urma compresiei pot afecta negativ procesul de detecție, deoarece pot masca anomaliile lăuate de algoritmi de falsificare, generând rezultate eronate (fals pozitive sau fals negative). Această problemă este documentată și în [20], unde autorii arată că MFNN are cel mai mare avantaj față de alte metode tocmai pe videoclipuri cu compresie puternică (C40). Din acest motiv, pentru antrenarea rețelei a fost utilizat setul FaceForensics++ la calitate ridicată, chiar dacă acest lucru implică un volum de date mai mare.

2.2 Diverse abordări asupra problemei

O imagine de ansamblu completă asupra peisajului actual al deepfake-urilor și al metodelor de detecție este prezentată în survey-ul lui Tolosana et al. [18], care cataloghează și compară sistematic principalele arhitecturi folosite în domeniu. Pe baza acestei perspective generale, în continuare sunt prezentate cele mai relevante trei categorii de soluții.

2.2.1 Abordarea Academică (FaceForensics++)

Pentru antrenarea și evaluarea sistemelor de detecție, o metodă de referință în mediul academic este FaceForensics++ [16]. Aceasta pune la dispoziție un set de date de peste 1,8 milioane de imagini, care conține atât videoclipurile originale, cât și variantele lor falsificate prin metode cunoscute precum DeepFakes sau FaceSwap. Un mare avantaj al acestei abordări este că simulează condiții din lumea reală, inclusiv artefacte de compresie video, ajutând rețeaua neuronală să recunoască urmele subtile ale manipulării. Tot în categoria soluțiilor academice intră și MesoNet [11], o rețea neuronală compactă special proiectată pentru detecția falsurilor faciale, care se concentrează exclusiv pe artefactele mezoscopice.

2.2.2 Abordarea Biometrică (Intel FakeCatcher)

O altă abordare interesantă este sistemul FakeCatcher de la Intel, care detectează falsurile analizând semnături biologice. Concret, algoritmul urmărește mișcările naturale ale ochilor și folosește fotopletismografia (PPG) pentru a depista schimbările subtile ale fluxului de sânge de sub piele – detalii pe care IA generativă nu le poate imita. Deși este o idee inovatoare, metoda are limitări practice evidente: ignoră componenta audio, devine inefficientă pe videoclipuri pixelate și are tendința de a clasifica eronat clipuri complet reale ca false, din exces de precauție. [22]

2.2.3 Detectoarele Comerciale (API-uri Cloud)

Deși există numeroase platforme online pentru detecție, acestea nu oferă o garanție reală în privința eficienței, fiind de cele mai multe ori contra cost. O problemă și mai serioasă o reprezintă confidențialitatea datelor: aceste companii folosesc algoritmi de tip black-box, iar utilizatorul nu are nicio siguranță că imaginile sale nu sunt stocate sau vândute către terți. Din acest motiv, încărcarea unor date sensibile pe astfel de site-uri reprezintă o limitare majoră în utilizarea lor profesională. [24]

3. Descrierea problemei și prezentarea soluției propuse

3.1 Obiectivele proiectului

Obiectivul principal al proiectului constă în dezvoltarea unui sistem automatizat capabil să extragă, să proceseze și să clasifice fluxurile video în vederea identificării manipularilor de tip deepfake. Deoarece calitatea datelor de antrenament este esențială pentru obținerea unor

rezultate valide, a fost selectat setul de date FaceForensics++, un standard academic ce include manipulări complexe precum FaceSwap și Face2Face [15]. Acest corpus de date permite modelului să identifice „urmele” și artefactele vizuale lăsate inevitabil în urmă de algoritmii de falsificare.

Din punct de vedere arhitectural, accentul a fost pus pe eficiență computațională. S-a optat pentru arhitectura ResNet18 integrată cu tehnica de Transfer Learning [5], valorificând astfel filtrele pre-antrenate pe milioane de imagini din setul ImageNet. Marele avantaj al acestei abordări este că reușim să detectăm falsurile rapid și cu acuratețe ridicată, dar cu un consum de resurse suficient de mic pentru ca aplicația să ruleze direct pe un calculator obișnuit, evitându-se dependența de infrastructuri masive de tip cloud [7].

3.2 Abordarea aleasă în proiect

3.2.1 Fundamentarea teoretică a detecției și analiza artefactelor

Pentru a fundamenta mecanismul de detecție, este necesară modelarea matematică a procesului de generare. Modelele actuale se bazează frecvent pe Autoencodere și rețele generative antagoniste (GAN) [2]. Procesul de sinteză este definit generic de funcția de reconstrucție $\hat{x} = D(E(x))$, unde modulul E (encoderul) comprimă expresia feței originale x , iar D (decoderul) o reconstruiește aplicând trăsăturile identității țintă.

Deoarece această încrucișare forțată a identităților nu este niciodată perfectă, erorile de reconstrucție apar pe trei niveluri exploatate direct de sistemul de detecție [20]:

- **Artefacte Microscopice (Statistice):** erori foarte mici, la nivel de pixel, sau zgomot statistic invizibil cu ochiul liber. Ele apar din cauza calculelor matematice ale rețelelor generative (GAN) și sunt captate de primele straturi ale rețelei (Shallow Layers).
- **Artefacte Mezoscopice (Texturi):** defecte vizibile pe zone mici, cum ar fi o textură nenaturală a pielii sau reflexii greșite în ochi. Acestea sunt identificate de straturile de mijloc (Middle Layers). O abordare care se concentrează exclusiv pe acest tip de artefacte este MesoNet [11].
- **Artefacte Macroscopice (Semantice):** defectele mari de logică și proporție – de exemplu, dacă nasul nu este aliniat corect cu ochii sau forma feței este deformată. Aceste defecte sunt extrase de ultimele straturi, cele mai profunde (Deep Layers).




Figura 1: Exemple de artefacte vizuale specifice manipulărilor deepfake: (a) Chip falsificat; (b) Chip original; (c) Contururi anormale și neregulate la nivelul obrazilor; (d) Lipsa detaliilor naturale de umbrire; (e) Halou cromatic nenatural (purpuriu) în regiunea buzelor; (f) Distorsiuni geometrice ale feței. (sursă: [20]).

Un aspect critic îl reprezintă artefactele de tip *face warping* [12]. Atunci când masca generată este suprapusă peste fața originală, la granițele de îmbinare apar distorsiuni caracteristice. Din acest motiv, etapa de preprocesare extinde aria de decupaj cu un factor de 1.4x în raport cu centrul feței detectate. Această decizie inginerească garantează că rețeaua reține și analizează zona de îmbinare (*blending*), cum ar fi linia maxilarului și regiunea gâtului, unde dovezile falsificării sunt pronunțate.

3.2.2 Arhitectura convoluțională

Arhitectura principală valorifică Rețelele Neuronale Convoluționale (CNN). Operația fundamentală, convoluția discretă bidimensională, este descrisă matematic prin ecuația:

$$(I * K)[i, j] = \sum_m \sum_n I[i + m, j + n] \cdot K[m, n]$$

unde I reprezintă matricea imaginii de intrare, iar K este filtrul convoluțional (kernelul) care glisează spațial peste imagine pentru a detecta trăsături vizuale locale, precum muchii sau texturi specifice.

3.2.3 Conceptul arhitectural Multi-Layer Fusion (MFNN)

Un CNN funcționează inerent într-o manieră ierarhică, particularitate care se aliniază perfect cu cele trei niveluri de erori menționate anterior. Strategia implementată, denumită MFNN (*Multi-Layer Fusion Neural Network*), presupune extragerea și fuzionarea hărților de caracteristici (*feature maps*) din straturi situate la adâncimi diferite, anterior luării deciziei finale. Această ierarhie de extragere corespunde direct tipologiei defectelor: straturile de suprafață (*Shallow*) captează zgomotul microscopic, cele intermediare (*Middle*) identifică

defectele de textură (mezoscopice), iar cele profunde (*Deep*) analizează contextul global și proporțiile feței (macroscopice) [20].




Figura 2: Arhitectura MFNN cu extragerea caracteristicilor pe trei niveluri de adâncime – Shallow, Middle și Deep – înainte de fuziunea finală pentru clasificare (sursă: [20]).

3.2.4 Alinierea dimensională și Funcția de decizie

O provocare conceptuală în fuziunea straturilor multiple constă în diferența de dimensionalitate dintre hărțile de caracteristici extrase la adâncimi diferite. În timp ce straturile de suprafață oferă o rezoluție spațială ridicată, cele profunde oferă o densitate mai mare a informației abstracte. Soluția propusă utilizează operații de aliniere dimensională pentru a aduce toți tensorii la un format compatibil înainte de concatenarea acestora într-un vector de caracteristici unic.

În etapa finală, pentru a asigura stabilitatea deciziei pe întregul flux video și a minimiza alarmele false cauzate de mișcări bruște (*motion blur*) sau artefacte de compresie, a fost formalizată o strategie de decizie prin Vot Majoritar (*Majority Voting*). Verdictul final V al videoclipului este determinat de următoarea funcție:

$$V = \begin{cases} FAKE, & \text{daca } \frac{1}{N} \sum_{i=1}^N P(c_i) > 0.5 \\ REAL, & \text{altfel} \end{cases}$$

unde N este numărul total de cadre extrase și analizate dintr-un videoclip, iar $P(c_i)$ reprezintă probabilitatea atribuită de rețea fiecărui cadru individual $c_{\{i\}}$. Această abstractizare statistică atenuează fluctuațiile de moment și garantează un rezultat general mult mai robust comparativ cu evaluările individuale stricte.

4. Implementarea tehnică a aplicației

4.1 Arhitectura generală a sistemului

Implementarea programului începe prin configurarea mediului de lucru și selectarea hardware-ului. Pentru a asigura o procesare rapidă, sistemul este setat să folosească suportul nativ CUDA din PyTorch, astfel încât modelul să ruleze direct pe placa video (GPU), care este mult mai potentă decât procesorul pentru calcule matriciale în paralel.

În etapa de pregătire a datelor, procesez videoclipurile folosind biblioteca OpenCV pentru a extrage cadrele, iar apoi aplic MediaPipe pentru a detecta și decupa precis doar fețele umane. Pentru a fi compatibile cu rețeaua neuronală, aceste decupaje sunt redimensionate la standardul de 224×224 pixeli și transformate în tensori. Pentru clasificare, am integrat ResNet18 pre-antrenat, pe care l-am adaptat prin Transfer Learning pentru detectarea celor trei tipuri de artefacte specifice deepfake-urilor. În final, am validat rezultatele evaluând modelul pe un set de testare izolat, obținut printr-o împărțire clasică a bazei de date (80% pentru antrenare și 20% pentru testare).

4.2 Preprocesarea datelor și detectarea facială

Operarea pe cadre statice izolate s-a dovedit a fi mai eficientă decât procesarea secvențială a fișierelor video. Prin urmare, etapa inițială de pregătire a datelor a presupus scrierea unui script Python, bazat pe biblioteca OpenCV, pentru divizarea conținutului video. Algoritmul utilizează funcția `cv2.VideoCapture` pentru a accesa fluxul video, salvând fiecare cadru ca o imagine independentă. Această procedură transformă datele video brute într-un set de date structurat, adecvat pentru antrenarea modelelor de inteligență artificială.

4.2.1 Tranziția de la metodele clasice la MediaPipe

Pentru localizarea și extragerea regiunilor faciale, metodele tradiționale, precum clasificatorul Haar Cascade din OpenCV, prezintă limitări semnificative. Deși acești algoritmi realizează o detecție de bază prin scanarea repetitivă a cadrelor, performanța lor scade în procesarea secvențelor video complexe. [27]

Din acest motiv, a fost selectată o soluție de ultimă generație: biblioteca MediaPipe, dezvoltată de Google, utilizând modelul BlazeFace. [13] Această arhitectură este optimizată specific pentru deducția în timp real, consumând resurse computaționale minime, dar oferind o viteză de execuție și o precizie de detecție superioare algoritmilor clasici.

Implementarea practică integrează funcționalitățile ambelor biblioteci. Fluxul de lucru presupune preluarea cadrului prin OpenCV și conversia spațiului de culoare din standardul BGR în RGB, cerință necesară pentru procesarea prin MediaPipe. Ulterior, modelul BlazeFace extrage coordonatele spațiale ale feței (bounding box). Această metodă hibridă asigură o prelucrare rapidă și precisă a volumelor mari de date video.

4.2.2 Optimizarea algoritmului de extracție pentru Deepfake-uri

Un detaliu practic important în faza de preprocesare constă în modul de realizare a decupării faciale. În loc de o tăiere clasică, limitată strict la perimetrul feței detectate, algoritmul a fost modificat pentru a lărgi coordonatele de decupare cu un factor de 1.4x față de centrul feței. Această ajustare are la bază un motiv tehnic legat de modul în care sunt generate deepfake-urile: erorile de sinteză și artefactele de îmbinare (blending artifacts) apar cel mai des la granița dintre masca artificială și capul original – mai exact pe linia maxilarului, pe gât sau pe marginea frunții [17]. O decupare prea strânsă a imaginii ar elimina tocmai aceste zone periferice critice, iar rețeaua neuronală ar pierde indicii vizuale esențiale ale falsificării. De

altfel, această abordare respectă direct implementarea din lucrarea originală a arhitecturii MFNN [20], unde este utilizată cu succes exact aceeași extindere de 1.4x

4.2.3. Standardizarea și redimensionarea setului de date

Ultimul pas din faza de preprocesare a constat în aducerea tuturor decupajelor faciale la o dimensiune standard. Cu ajutorul bibliotecii OpenCV, imaginile extrase au fost redimensionate la o rezoluție fixă de 256×256 pixeli. Această etapă este o cerință tehnică obligatorie: fără o rezoluție constantă la intrarea în model, rețeaua neuronală nu ar putea să proceseze și să alinieze corect hărțile de caracteristici (*feature maps*) în straturile sale mai adânci [28].

4.3. Arhitectura Multi-Layer Fusion Neural Network (MFNN)

Baza tehnologică a acestui proiect este o rețea neuronală cu fuziune multi-strat (MFNN – Multi-Layer Fusion Neural Network). Spre deosebire de metodele clasice de clasificare, care iau decizia uitându-se doar la rezultatul final al rețelei, arhitectura MFNN caută urmele falsificării în mai multe stadii de procesare, simultan. [8]

4.3.1 Rețeaua de bază (backbone) și extragerea caracteristicilor

Pentru implementarea practică, arhitectura ResNet18 a fost aleasă ca rețea principală (backbone), deoarece oferă un compromis optim între performanța de detecție și resursele hardware disponibile [7]. Pentru a optimiza timpul de antrenare, s-a utilizat tehnica de Transfer Learning [5], pornind de la o rețea deja pre-antrenată pe setul de date ImageNet. Contribuția specifică a acestei implementări constă în modificarea fluxului de execuție pentru analiza internă a rețelei. Astfel, în loc să fie evaluată doar ieșirea finală a modelului, arhitectura a fost adaptată pentru a extrage simultan hărțile de caracteristici (*feature maps*) din trei puncte distincte: un nivel de suprafață (imediat după primul bloc convoluțional), un nivel intermediar (după al doilea bloc) și un nivel profund (la finalul rețelei).

4.3.2 Alinierea dimensiunilor și fuziunea datelor

O provocare tehnică în combinarea celor trei niveluri de extracție este diferența de dimensionalitate dintre ele. Primele straturi convoluționale generează hărți de caracteristici cu o rezoluție spațială mare, dar cu un număr redus de canale, în timp ce straturile profunde produc hărți cu rezoluție mică, dar cu o adâncime mult mai mare a canalelor.

Pentru a permite fuziunea acestora, au fost introduse operații de convoluție suplimentare care aliniază toate cele trei fluxuri de date la un format comun: un tensor cu rezoluția spațială de 8×8 și o adâncime de 256 de canale. În mod concret, pentru extracția de suprafață s-a aplicat o reducere dimensională (*downsampling*) folosind un filtru de 8×8 cu pasul (*stride*) de 8. Pentru nivelul intermediar s-a utilizat o reducere moderată cu un filtru de 4×4 și pas de 4, iar pentru extracția profundă – care are deja dimensiunea spațială necesară de 8×8 – s-a aplicat o convoluție de 1×1 exclusiv pentru a uniformiza numărul de canale la 256. La final, cele trei seturi de caracteristici, devenite astfel compatibile dimensional, sunt concatenate într-un tensor unic, oferind clasificatorului o reprezentare vizuală completă pentru luarea deciziei.

4.4 Metodologia de antrenare și optimizare (Fine-Tuning)

Definirea arhitecturii MFNN constituie doar o etapă a dezvoltării sistemului. Pentru ca modelul să poată clasifica precis cadrele autentice și pe cele falsificate, a fost necesară

implementarea unei strategii de antrenare riguroase. Principalul obiectiv al acestei etape este atenuarea fenomenului de overfitting (supraspecializarea pe setul de date inițial) și maximizarea capacității de generalizare, asigurând astfel recunoașterea corectă a manipulărilor în materiale video neîntâlnite anterior.

4.4.1. Augmentarea datelor pentru o generalizare optimă

Pentru a preveni fenomenul de overfitting (supraspecializarea pe datele de antrenament), a fost integrată o etapă de augmentare dinamică a datelor la fiecare iterație (epoch). În mod specific, s-au aplicat transformări geometrice și coloristice aleatoare asupra cadrelor, precum: rotații de până la 15 grade pentru a simula variațiile naturale ale posturii capului, reflexii orizontale, și ajustări ale luminozității și contrastului cu un factor de 20% (Color Jitter) pentru a simula diverse condiții de iluminare. Scopul acestor alterări controlate este de a crește artificial varianța datelor de intrare, forțând rețeaua să extragă trăsăturile robuste, specifice manipulării deepfake, în loc să memoreze caracteristici contextuale irelevante [10].

4.4.2 Gestionarea dezechilibrului dintre clase

O provocare inherentă seturilor de date pentru detecția deepfake este dezechilibrul major dintre clase, marcat de un volum substanțial mai mare de cadre falsificate comparativ cu cele autentice. Antrenarea directă pe o astfel de distribuție ar induce un *bias* (o părtinire) modelului, acesta având tendința de a clasifica majoritatea cadrelor ca fiind „Fake” strict pe baza probabilității statistice din setul de date [14]. Pentru a compensa această problemă de distribuție, s-a utilizat modulul `WeightedRandomSampler` din biblioteca PyTorch [31]. Algoritmul atribuie ponderi dinamice fiecărui eșantion pe baza frecvenței clasei sale, asigurând astfel o probabilitate crescută de extracție pentru imaginile din clasa minoritară („Real”). În consecință, fiecare lot de date (*batch*) de 32 de imagini procesat de rețea menține o proporție echilibrată a claselor, facilitând convergența corectă a algoritmului.

4.4.3 Optimizarea globală (Fine-Tuning)

Deși abordarea convențională în tehnicile de *Transfer Learning* presupune înghețarea greutateilor (*weights*) din straturile inițiale și antrenarea exclusivă a stratului final de clasificare, natura subtilă a artefactelor deepfake a impus o strategie de tip *Global Fine-Tuning* [9]. Astfel, greutateile întregii arhitecturi ResNet18 au fost deblocate (*unfrozen*), permițând actualizarea inclusiv a filtrelor de convoluție primare pentru a putea capta zgomotul digital fin, lăsat de procesul de generare artificială. Pentru a asigura stabilitatea pe parcursul antrenării s-a utilizat optimizatorul Adam [4], cuplat cu o rată de învățare (*learning rate*) foarte redusă, setată la 0.0001. Această parametrizare este critică: permite ajustarea fină a ponderilor pe baza noilor date, contracaraând în același timp fenomenul de uitare catastrofală (*catastrophic forgetting*), prin care modelul ar pierde trăsăturile vizuale generale extrase în faza pre-antrenării pe setul ImageNet [6].

4.5 Evaluarea pe material video (Inferența)

Faza finală de execuție a sistemului constă în etapa de inferență, respectiv aplicarea practică a modelului pe date video noi pentru obținerea unui verdict binar (REAL sau FAKE). Pentru a optimiza raportul dintre timpul de execuție și acuratețea predicției, procesul a fost structurat în două etape complementare.

4.5.1 Procesarea rapidă a cadrelor

Din considerente de performanță computațională, s-a evitat procesarea exhaustivă a tuturor cadrelor din fluxul video. Utilizând biblioteca OpenCV, s-a implementat o subeșantionare temporală prin extragerea unui singur cadru din cinci. Această metodă reduce volumul de date

procesate cu aproximativ 80%, menținând totodată o rezoluție temporală suficientă pentru a asigura corectitudinea analizei faciale. Cadrele extrase parcurg automat fluxul de preprocesare stabilit: localizarea prin algoritmul BlazeFace, decuparea cu factorul de extindere de 1.4x și redimensionarea strictă la 256×256 pixeli. Tensorul rezultat este propagat prin rețeaua MFNN, iar ieșirea acesteia este evaluată prin funcția de activare Softmax [30]. Aceasta din urmă mapează valorile brute (*logits*) generate de rețea într-o distribuție de probabilitate clară (de exemplu, 92% grad de certitudine pentru clasa falsificată).

4.5.2 Strategia de vot majoritar (Majority Voting)

Evaluarea unui videoclip bazându-se exclusiv pe o singură imagine prezintă un grad ridicat de incertitudine, sistemul fiind vulnerabil la artefacte introduse de comprimare, mișcări bruște (*motion blur*) sau pierderi temporare de focalizare. Pentru a asigura robustețea clasificării, s-a implementat un mecanism de decizie bazat pe vot majoritar (*Majority Voting*) [3]. Algoritmul centralizează probabilitățile generate pentru toate cadrele analizate dintr-un videoclip; orice cadru evaluat cu o probabilitate de peste 50% de a fi manipulat este contabilizat ca un vot pozitiv pentru clasa „Fake”. Verdictul final la nivel de videoclip este determinat de clasa majoritară. Această agregare statistică atenuează semnificativ impactul erorilor izolate, oferind un rezultat mult mai stabil și mai de încredere comparativ cu predicțiile individuale la nivel de cadru.

4.6. Interfața grafică și testarea practică

Pentru a valida funcționalitatea proiectului pe un set de videoclipuri noi, complet necunoscute modelului, am dezvoltat o interfață grafică (GUI) interactivă utilizând biblioteca tkinter din Python. Fereastra aplicației a fost gândită să fie intuitivă și este împărțită vizual în patru secțiuni principale.




Figura 3: Interfața principală a sistemului la momentul inițializării, pregătită pentru date.

4.6.1 Secțiunea de Input și Modurile de Analiză (Panoul din stânga)

În prima secțiune, utilizatorul poate încărca videoclipul pe care dorește să îl verifice, folosind un meniu de selecție clasic din Windows. Imediat sub acesta, se află panoul de control pentru tipul de analiză, care oferă două opțiuni:

- **Clean Test:** O analiză normală a videoclipului, fix la calitatea la care a fost încărcat.
- **Stress Test Live:** Un modul special pe care l-am creat pentru a testa limitele de detecție ale modelului. Prin intermediul unui meniu drop-down, videoclipul poate fi supus intenționat unor degradări de calitate, de la compresie JPEG până la blur extrem sau distorsionarea pixelilor.




Figura 4: Meniul drop-down pentru selectarea tipului de degradare în modul Stress Test.

4.6.2 Live Preview și recunoașterea facială (Centru)

Cea mai mare secțiune a interfeței este vizualizarea în timp real (*Live Preview*). Aici, videoclipul rulează pe parcursul analizei, iar sistemul afișează un contur vizual (*bounding box*) în momentul în care detectează și extrage fața subiectului. Un detaliu tehnic important este că modificările de limitare aplicate din meniul „Stress Test” se aplică vizual și direct pe acest preview. Astfel, utilizatorul poate vedea exact gradul de distrugere a imaginii cu care trebuie să lucreze rețeaua.

4.6.3 Verdictul final și Graficul de Încredere (Panoul din dreapta)

În panoul din dreapta sunt raportate rezultatele. În partea de sus, se calculează constant scorul de probabilitate Deepfake/Real pe baza strategiei de „vot majoritar” (*Majority Voting*), oferind într-un final verdictul. În jumătatea de jos, am integrat un grafic cu bare care se desenează live. Acesta arată gradul de încredere (*confidence*) al modelului pentru absolut fiecare cadru extras (barele ilustrând procentul pentru predicția aleasă).




Figura 5: Rularea unui test normal (Clean Test) care identifică cu succes conținutul manipulat (bare roșii dominante).

4.6.4 Observații privind performanța și limitările modelului

Testând funcționalitatea pe clipuri noi, am observat clar comportamentul rețelei în condiții vitrege. În timp ce la un test normal rezultatele sunt foarte bune, performanța scade dramatic dacă folosim funcția de „Stress Test” cu opțiuni precum artefacte de compresie vizuală puternică.




Figura 6: Rularea unui „Stress Test” care induce modelul în eroare, returnând un verdict de autenticitate pentru un clip deepfake.

Așa cum se poate observa din graficul de încredere generat în timpul testului de stres (barele devenind verzi), modelul tinde să ofere rezultate fals-negative (consideră clipul ca fiind real). Motivul tehnic din spatele acestei vulnerabilități este clar: compresia puternică sau pixelarea acționează ca o „netezire” forțată, distrugând complet acele artefacte fine și urme microscopice lăsate de falsificare pe care rețeaua neuronală învățase să le recunoască.

5. Concluzii si planuri de viitor

Prezentul proiect a vizat dezvoltarea unui sistem funcțional de detecție a manipulărilor video de tip deepfake, fundamentat pe o arhitectură neuronală cu fuziune multi-strat (MFNN). Toate obiectivele tehnice propuse au fost atinse cu succes: extragerea automată a cadrelor prin intermediul bibliotecii OpenCV, detecția și decuparea facială utilizând MediaPipe (cu aplicarea unei marje de extindere de 1.4x pentru reținerea artefactelor periferice), antrenarea rețelei MFNN pentru analiza simultană a trăsăturilor la trei niveluri de profunzime, precum și încapsularea soluției într-o aplicație desktop interactivă bazată pe Tkinter.

5.1 Performanța obținută

La testarea finală pe setul de validare (reprezentând 20% din imaginile FaceForensics++ [16]), modelul a obținut o acuratețe de 97.07% pentru clasificarea la nivel de cadru. Aceasta este o valoare foarte bună, iar analizând matricea de confuzie se observă că rata alarmelor false a fost ținută sub control (modelul a greșit doar pe 1134 de cadre din cele peste 16.000 de fețe reale). Prin aplicarea ulterioară a strategiei de vot majoritar pe un videoclip întreg, decizia sistemului va deveni și mai stabilă. Pentru context, arhitectura MFNN originală [20] a raportat 100% acuratețe pe videoclipuri fără compresie (C0) și 98.97% pe o compresie medie (C23). Faptul că implementarea mea a atins 97.07% arată că rezultatele sunt competitive și comparabile cu stadiul actual al cercetării, mai ales ținând cont că am utilizat arhitectura ResNet18 pentru a menține un consum redus de resurse (rulabil pe un PC normal), în loc să folosesc arhitectura masivă din lucrarea originală.




Figura 7: Matricea de confuzie pentru setul de date de testare nealterat

Totuși, pentru a valida cu adevărat robustețea sistemului, am rulat și un set de scenarii dificile (un test de stres). Concret, am modificat imaginile aplicând o compresie puternică (simulând calitatea slabă a unui videoclip descărcat de pe internet), am scăzut luminozitatea și am adăugat zone de ocluzie pe fețe. Pe aceste cazuri distructive, acuratețea a scăzut abrupt la

31.84%, iar din matricea de confuzie reiese că modelul a început să clasifice aproape toate imaginile falsificate ca fiind autentice. Deși reprezintă o scădere mare, acest rezultat demonstrează practic limitarea principală a rețelei: modelul învață să recunoască deepfake-urile căutând artefacte foarte fine și imperfecțiuni la nivel de pixel. Atunci când calitatea imaginii este distrusă de compresie, acele „urme” artificiale dispar complet, iar rețeaua nu mai are indiciile necesare pentru a face diferența. Acest comportament este absolut normal și este perfect aliniat cu concluziile din lucrările [20] și [18], care confirmă că artefactele mascate de compresie reprezintă principalul factor de eroare al sistemelor de detecție.




Figura 8: Matricea de confuzie pentru setul de date de testare alterat

5.2 Limitări

Sistemul prezintă și câteva limitări. Modelul se descurcă mai greu dacă videoclipul testat are o calitate vizuală foarte proastă (compresie puternică, iluminare slabă) sau dacă fața este parțial acoperită, deoarece acele mici dovezi lăsate de falsificare devin invizibile pentru rețea. De asemenea, sistemul nu analizează componenta audio, lăsând nedetectate falsurile de tip voice cloning.

5.3 Dezvoltări viitoare

Pe viitor, proiectul ar putea fi extins în mai multe direcții: adăugarea analizei audio-video pentru verificarea sincronizării dintre voce și mișcarea buzelor, optimizarea modelului în format ONNX pentru inferența în timp real pe apeluri video live, și trecerea la arhitecturi bazate pe mecanisme de atenție, precum Vision Transformers (ViT), care au demonstrat rezultate superioare în literatura recentă [19].

6. Bibliografie

- [1] Lin, M., Chen, Q., & Yan, S. (2013). Network In Network. arXiv:1312.4400.
<https://arxiv.org/abs/1312.4400>
- [2] Goodfellow, I. J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... Bengio, Y. (2014). Generative Adversarial Networks. arXiv:1406.2661.
<https://doi.org/10.48550/arXiv.1406.2661>

- [3] Karpathy, A., Toderici, G., Shetty, S., Leung, T., Sukthankar, R., & Fei-Fei, L. (2014). Large-scale Video Classification with Convolutional Neural Networks. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1725–1732. https://cv-foundation.org/openaccess/content_cvpr_2014/html/Karpathy_Large-scale_Video_Classification_2014_CVPR_paper.html
- [4] Kingma, D. P., & Ba, J. L. (2014). Adam: A Method for Stochastic Optimization. arXiv:1412.6980. <https://arxiv.org/abs/1412.6980>
- [5] Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? Advances in Neural Information Processing Systems (NIPS), 27, pp. 3320–3328. <https://arxiv.org/abs/1411.1792>
- [6] Goodfellow, I. J., Mirza, M., Xiao, D., Courville, A., & Bengio, Y. (2015). An Empirical Investigation of Catastrophic Forgetting in Gradient-Based Neural Networks. arXiv:1312.6211. <https://arxiv.org/abs/1312.6211>
- [7] He, K., Zhang, X., Ren, S., & Sun, J. (2015). Deep Residual Learning for Image Recognition. arXiv:1512.03385. <https://arxiv.org/abs/1512.03385>
- [8] Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S. (2017). Feature Pyramid Networks for Object Detection. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). <https://arxiv.org/abs/1612.03144>
- [9] Tajbakhsh, N., Shin, J. Y., Gurudu, S. R., Hurst, R. T., Kendall, C. B., Gotway, M. B., & Liang, J. (2017). Convolutional Neural Networks for Medical Image Analysis: Full Training or Fine Tuning? IEEE Transactions on Medical Imaging. <https://arxiv.org/abs/1706.00712>
- [10] Taylor, L., & Nitschke, G. (2017). Improving Deep Learning using Generic Data Augmentation. arXiv:1708.06020. <https://arxiv.org/abs/1708.06020>
- [11] Afchar, D., Nozick, V., Yamagishi, J., & Echizen, I. (2018). MesoNet: A Compact Facial Video Forgery Detection Network. IEEE International Workshop on Information Forensics and Security (WIFS). arXiv:1809.00888. <https://arxiv.org/abs/1809.00888>
- [12] Li, Y., & Lyu, S. (2018). Exposing DeepFake Videos By Detecting Face Warping Artifacts. arXiv:1811.00656. <https://arxiv.org/abs/1811.00656>
- [13] Bazarevsky, V., Kartynnik, Y., Vakunov, A., Raveendran, K., & Grundmann, M. (2019). BlazeFace: Sub-millisecond Neural Face Detection on Mobile GPUs. arXiv:1907.05047. <https://arxiv.org/abs/1907.05047>
- [14] Johnson, J. M., & Khoshgoftaar, T. M. (2019). Survey on deep learning with class imbalance. Journal of Big Data, 6(27). <https://doi.org/10.1186/s40537-019-0192-5>
- [15] Rössler, A., Cozzolino, D., Verdoliva, L., Riess, C., Thies, J., & Nießner, M. (2019). FaceForensics: A Large-scale Video Dataset for Forgery Detection in Human Faces. arXiv:1803.09179. <https://arxiv.org/abs/1803.09179>
- [16] Rössler, A., Cozzolino, D., Verdoliva, L., Riess, C., Thies, J., & Nießner, M. (2019). FaceForensics++: Learning to Detect Manipulated Facial Images. IEEE International Conference on Computer Vision (ICCV). arXiv:1901.08971. <https://arxiv.org/abs/1901.08971>
- [17] Li, L., Bao, J., Zhang, T., Yang, H., Chen, D., Wen, F., & Guo, B. (2020). Face X-ray for More General Face Forgery Detection. arXiv:1912.13458. <https://arxiv.org/abs/1912.13458>

- [18] Tolosana, R., Vera-Rodriguez, R., Fierrez, J., Morales, A., & Ortega-Garcia, J. (2020). DeepFakes and Beyond: A Survey of Face Manipulation and Fake Detection. *Information Fusion*, 64, pp. 131–148. arXiv:2001.00179. <https://arxiv.org/abs/2001.00179>
- [19] Mirsky, Y., & Lee, W. (2021). The Creation and Detection of Deepfakes: A Survey. *ACM Computing Surveys*, 54(1), pp. 1–41. arXiv:2004.11138. <https://arxiv.org/abs/2004.11138>
- [20] Zhao, Z., Wang, P., & Lu, W. (2021). Multi-Layer Fusion Neural Network for Deepfake Detection. *International Journal of Digital Crime and Forensics (IJDCF)*, 13(4). DOI: 10.4018/IJDCF.20210701.oa3
. https://www.researchgate.net/publication/352884012_Multi-Layer_Fusion_Neural_Network_for_Deepfake_Detection
- [21] Busch, E., & Ware, J. (2023). The Weaponisation of Deepfakes: Digital Deception by the Far-Right. ICCT Policy Brief.
- [22] Clayton, J. (2023, 23 iulie). Intel's deepfake detector tested on real and fake videos. BBC News Technology. Accesat aprilie 2026, de la <https://www.bbc.com/news/technology-66267961>
- [23] McKinsey & Company. (2023). The state of AI in 2023: Generative AI's breakout year. McKinsey Global Publishing. Accesat 14 aprilie 2026, de la <https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai-in-2023-generative-ais-breakout-year>
- [24] Luqman, A., Mahesh, R., & Chattopadhyay, A. (2024). Privacy and Security Implications of Cloud-Based AI Services: A Survey. arXiv:2402.00896. <https://arxiv.org/abs/2402.00896>
- [25] UNESCO & CLACSO. (2024). Artificial intelligence and democracy. Paris/Montevideo: UNESCO & The Latin American Council of Social Sciences (CLACSO).
- [26] Nastas, A. (fără an). Grafica pe calculator [Note de curs]. Universitatea Tehnică a Moldovei, Facultatea Calculatoare, Informatică și Microelectronică.
- [27] OpenCV Team. (fără an). Cascade Classifier. OpenCV 4.x Documentation. Accesat aprilie 2026, de la https://docs.opencv.org/4.x/db/d28/tutorial_cascade_classifier.html
- [28] OpenCV Team. (fără an). Geometric Image Transformations: Resize. OpenCV 4.x Documentation. Accesat aprilie 2026, de la https://docs.opencv.org/4.x/da/d54/group_imgproc__transform.html
- [29] Python Software Foundation. (fără an). Thread-based parallelism. Python 3 Documentation. Accesat aprilie 2026, de la <https://docs.python.org/3/library/threading.html>
- [30] PyTorch Team. (fără an). torch.nn.Softmax. PyTorch Documentation. Accesat aprilie 2026, de la <https://pytorch.org/docs/stable/generated/torch.nn.Softmax.html>
- [31] PyTorch Team. (fără an). torch.utils.data.WeightedRandomSampler. PyTorch Documentation. Accesat aprilie 2026, de la <https://pytorch.org/docs/stable/data.html#torch.utils.data.WeightedRandomSampler>
- [32] PyTorch Team. (fără an). Torchvision Transforms: ColorJitter. PyTorch Documentation. Accesat aprilie 2026, de la <https://pytorch.org/vision/stable/generated/torchvision.transforms.ColorJitter.html>
- [33] Restream. (fără an). What Is Video Compression? Restream Learn. Accesat 14 aprilie 2026, de la <https://restream.io/learn/what-is/video-compression/>

- [34] Tina, G., Heatley, P., Kim, J., Parks, S., & Reardon, M. (fără an). Increasing Threat of Deepfake Identities. U.S. Department of Homeland Security.
https://www.dhs.gov/sites/default/files/publications/increasing_threats_of_deepfake_identities_0.pdf

7. Declarație privind utilizarea asistenței LLM

În cadrul etapelor de documentare, dezvoltare și redactare a acestui proiect, au fost utilizate modele de tip Large Language Model (Google Gemini) strict în scop consultativ și de asistență tehnică, cu respectarea normelor de integritate academică conform Regulamentului UPB.

Instrumentele de inteligență artificială au fost folosite exclusiv pentru: clarificarea conceptelor avansate de Transfer Learning și identificarea resurselor bibliografice relevante; consultanță în identificarea erorilor de logică în PyTorch (setarea corectă a funcțiilor de pierdere, implementarea WeightedRandomSampler); sprijin în interpretarea metricilor de performanță (Matrice de Confuzie, compromisul Precision-Recall); și rafinarea stilistică a documentației.